



INFORMATIKOS, INŽINERIJOS IR TECHNOLOGIJŲ FAKULTETAS
INFORMATIKOS IR MEDIJŲ TECHNOLOGIJŲ KATEDRA

Almantas Kederys

PS-2/1 gr.

Banko klientų terminuoto indėlio pasirinkimo
prognozė taikant logistinę regresiją

Programų sistemos studijų programa

valstybinis kodas 6531BX041

Programų sistemos studijų kryptis

Vadovas Virgilijus Sakalauskas

Kaunas, 2025

TURINYS

1. Įvadas.....	3
2. Duomenų analizė	4
2.1. Duomenų struktūra.....	4
2.2. Duomenų ypatybės ir preliminarus požymių vertinimas	5
3. Duomenų importavimas ir atsitiktinio skirstymo paruošimas.....	6
3.1. Duomenų įkėlimas į BigQuery	6
3.2. Atsitiktinio skaičiaus stulpelio pridėjimas	7
4. Eksperimentinis modelių treniravimas ir duomenų transformacijų įtaka.....	9
4.1. Pradinis modelio treniravimas naudojant neapdorotus duomenis	9
4.2. Kintamojo “ <i>age</i> ” reikšmės vertinimas	14
4.3. Kintamojo “ <i>default</i> ” reikšmės vertinimas.....	16
4.4. Kintamojo “ <i>balance</i> ” reikšmės vertinimas	18
4.5. Kintamųjų “ <i>previous</i> ” ir “ <i>pdays</i> ” reikšmių vertinimas	21
4.6. Kintamojo “ <i>education</i> ” reikšmės vertinimas	24
4.7. Kintamojo “ <i>loan</i> ” reikšmės vertinimas.....	24
4.8. Kintamojo “ <i>campaign</i> ” reikšmės vertinimas	25
4.9. Likusiųjų kintamųjų vertinimas	27
4.10. Bazinio bei galutinio modelio palyginimas	30
5. Modelio įvertinimas.....	32
6. Prognozės atlikimas.....	34
7. Išvados.. ..	36

1. ĮVADAS

Darbo tikslas

Darbo tikslas – sukurti klasifikavimo modelį, kuris galėtų prognozuoti, ar banko klientas sudarys terminuotą indėlį (angl. „deposit“), remiantis istoriniais telemarketingo kampanijų duomenimis. Tokios prognozės gali padėti bankams tiksliau taikyti rinkodaros strategijas ir efektyviau paskirstyti išteklius, susitelkiant į tuos klientus, kurių tikimybė sudaryti indėlį yra didesnė.

Duomenų šaltinis

Šiame projekte analizuojamas duomenų rinkinys apima įvairius banko klientų požymius – tiek demografinius, tiek finansinius, taip pat duomenis apie ankstesnių marketingo kampanijų rezultatus. Tarp reikšmingiausių kintamųjų yra kliento amžius, darbo pobūdis, šeimyninė padėtis, paskolų istorija, vidutinis metinis likutis, kontaktavimo metodas, kontaktavimo mėnuo ir kita susijusi informacija, apie kiekvieną iš jų bus papasakota kitame skyriuje.

Pasirinktas mašininio mokymosi modelis

Šiam prognozavimo uždaviniui taikomas logistinės regresijos algoritmas. Tai yra klasikinis statistinis metodas, plačiai naudojamas dvejetainėms klasifikavimo užduotims – kai reikia nuspėti vieną iš dviejų galimų baigčių, šiuo atveju: „taip“ arba „ne“ dėl terminuoto indėlio sudarymo.

Logistinė regresija leidžia paprastai interpretuoti kintamųjų įtaką rezultatui, efektyviai apdoroti tiek kategorinius, tiek skaitinius, tiek sugrupuotus duomenis.

Darbo struktūra

Darbas susidės iš kelių pagrindinių dalių. Pirmiausia pateiksiu pirminę duomenų analizę bei duomenų paruošimo procesą, apimančią transformacijas, sugrupavimus ir kitus „feature engineering“ veiksmus. Tuomet bus atliekamas modelio treniravimas, pasitelkiant 80% duomenų, sekamas modelio įvertinimas pagal tikslumo (angl. „precision“), atsiminimo (angl. „recall“), F1 ir kitus rodiklius. Galiausiai modelis išbandomas su likusiais 20% duomenų, kurie nebuvo naudoti treniruojant, siekiant įvertinti modelio gebėjimą prognozuoti realiose situacijose.

2. DUOMENŲ ANALIZĖ

Šiame projekte naudojamas viešai prieinamas banko telemarketingo duomenų rinkinys, pasiekiamas per *Kaggle* platformą:

<https://www.kaggle.com/datasets/janiobachmann/bank-marketing-dataset/data>. Duomenų rinkinys susideda iš 11162 įrašų, kuriuose pateikiama informacija apie banko klientus ir jų sąveiką su telemarketingo kampanijomis. Kiekvienas įrašas atitinka vieno kliento vieną kontaktą su banku.

age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
59	admin.	married	secondary	no	2343	yes	no	unknown	5	may	1042	1	-1	0	unknown	yes
56	admin.	married	secondary	no	45	no	no	unknown	5	may	1467	1	-1	0	unknown	yes
41	technician	married	secondary	no	1270	yes	no	unknown	5	may	1389	1	-1	0	unknown	yes
55	services	married	secondary	no	2476	yes	no	unknown	5	may	579	1	-1	0	unknown	yes
54	admin.	married	tertiary	no	184	no	no	unknown	5	may	673	2	-1	0	unknown	yes
42	management	single	tertiary	no	0	yes	yes	unknown	5	may	562	2	-1	0	unknown	yes
56	management	married	tertiary	no	830	yes	yes	unknown	6	may	1201	1	-1	0	unknown	yes
60	retired	divorced	secondary	no	545	yes	no	unknown	6	may	1030	1	-1	0	unknown	yes
37	technician	married	secondary	no	1	yes	no	unknown	6	may	608	1	-1	0	unknown	yes
28	services	single	secondary	no	5090	yes	no	unknown	6	may	1297	3	-1	0	unknown	yes
38	admin.	single	secondary	no	100	yes	no	unknown	7	may	786	1	-1	0	unknown	yes
30	blue-collar	married	secondary	no	309	yes	no	unknown	7	may	1574	2	-1	0	unknown	yes
29	management	married	tertiary	no	199	yes	yes	unknown	7	may	1689	4	-1	0	unknown	yes
46	blue-collar	single	tertiary	no	460	yes	no	unknown	7	may	1102	2	-1	0	unknown	yes
31	technician	single	tertiary	no	703	yes	no	unknown	8	may	943	2	-1	0	unknown	yes
35	management	divorced	tertiary	no	3837	yes	no	unknown	8	may	1084	1	-1	0	unknown	yes
32	blue-collar	single	primary	no	611	yes	no	unknown	8	may	541	3	-1	0	unknown	yes
49	services	married	secondary	no	-8	yes	no	unknown	8	may	1119	1	-1	0	unknown	yes
41	admin.	married	secondary	no	55	yes	no	unknown	8	may	1120	2	-1	0	unknown	yes
49	admin.	divorced	secondary	no	168	yes	yes	unknown	8	may	513	1	-1	0	unknown	yes
28	admin.	divorced	secondary	no	785	yes	no	unknown	8	may	442	2	-1	0	unknown	yes
43	management	single	tertiary	no	2067	yes	no	unknown	8	may	756	1	-1	0	unknown	yes
43	management	divorced	tertiary	no	388	yes	no	unknown	8	may	2087	2	-1	0	unknown	yes
43	blue-collar	married	primary	no	-192	yes	no	unknown	8	may	1120	2	-1	0	unknown	yes

2.1. Duomenų struktūra.

Duomenų rinkinį sudaro šie stulpeliai (kintamieji):

- **age** – kliento amžius (skaitinis);
- **job** – kliento profesija (kategorinis);
- **marital** – šeimyninė padėtis: *married*, *single*, *divorced* (kategorinis);
- **education** – išsilavinimo lygis (kategorinis);
- **default** – ar klientas turi neapmokėtą paskolą (dvejjetainis: *yes/no*);
- **balance** – kliento vidutinė sąskaitos balanso reikšmė (skaitinis);
- **housing** – ar klientas turi būsto paskolą (dvejjetainis: *yes/no*);
- **loan** – ar klientas turi asmeninę paskolą (dvejjetainis: *yes/no*);
- **contact** – kontaktavimo tipas (*cellular/telephone/unknown*);
- **day** – mėnesio diena, kada klientas buvo kontaktuojamas (1–31).
- **month** – mėnuo, kada klientas buvo kontaktuojamas (kategorinis).


- **duration** – skambučio trukmė, sekundėmis.
- **campaign** – kiek kartų klientas buvo kontaktuos šios kampanijos metu;
- **pdays** – kiek dienų praėjo nuo paskutinio kontakto su klientu per ankstesnę kampaniją (reikšmė -1 reiškia, kad klientas dar niekada nebuvo kontaktuos);
- **previous** – kiek kartų klientas buvo kontaktuos ankstesnėse kampanijose;
- **poutcome** – ankstesnės kampanijos rezultatas (*success, failure, other, unknown*);
- **deposit** – priklausomas kintamasis: ar klientas sutiko sudaryti terminuotą indėlį (*yes/no*).

2.2. Duomenų ypatybės ir preliminarus požymių vertinimas

Remiantis duomenų apžvalga ir loginiais svarstymais, galima preliminariai įvertinti, kurie kintamieji gali būti naudingi modelio treniravimui:

Tikėtina naudingi požymiai:

- **age** – kliento amžius gali turėti įtakos sprendimui investuoti;
- **job** – profesija gali atspindėti socialinę-ekonominę statusą;
- **marital** – šeimyninė padėtis gali koreliuoti su finansiniu elgesiu;
- **education** – išsilavinimo lygis gali turėti reikšmės investavimo sprendimams;
- **default** – informacija apie nemokumą gali būti svarbi;
- **balance** – kliento vidutinė sąskaitos likučio reikšmė yra itin svarbi. Kadangi reikšmės labai įvairios (taip pat yra neigiamų, kas reiškia, jog klientas turėjo skolą), planuojama jas suskirstyti į intervalus (režius), kad palengvintų modelio interpretaciją ir treniravimą.



- **housing** ir **loan** – paskolų turėjimas gali rodyti kliento finansinius įsipareigojimus ir rizikos lygį;
- **contact** – kontaktavimo būdas gali paveikti kliento atsaką;
- **month** – galima pastebėti sezoniškumą, galbūt klientai labiau linkę užsisakyti terminuotą indėlį rudenį, bet ne vasarą ir pan.
- **campaign**, **pdays**, **previous**, **poutcome** – šie kintamieji atspindi kliento kontaktavimo istoriją ir gali būti naudingi prognozuojant jo elgseną.

Tikėtina mažiau naudingi požymiai:


- **day** – mėnesio diena, kada klientas buvo kontaktuojamas, greičiausiai neturi reikšmingos įtakos prognozei.
- **duration** – skambučio trukmė būtų labai informatyvi, tačiau ji yra žinoma tik po kontakto, t. y. ji nėra prieinama prieš klientui priimant sprendimą. Kadangi šio projekto tikslas – prognozuoti rezultatą *prieš* kontaktuojant, šis kintamasis nebus naudojamas modelyje.

3. DUOMENŲ IMPORTAVIMAS IR ATSITIKTINIO SKIRSTYMO PARUOŠIMAS

Duomenų analizę atlikus lokaliai, tolesniam apdorojimui ir užklausų vykdymui pasirinkta naudoti Google BigQuery platforma, kuri leidžia dirbti su dideliais duomenų kiekiais naudojant SQL užklausas debesijos aplinkoje.

3.1. Duomenų įkėlimas į BigQuery

Pradiniame etape duomenų failas bank.csv buvo įkeltas į BigQuery bei pavadintas *bank_telemarketing*, kuris patalpintas į sukurtą, *bank* pavadinimu, duomenų rinkinį (angl. “dataset”). Įkėlus duomenis, buvo sukurta lentelė su visais pirminiais stulpeliais:



Field name	Type
☐ age	INTEGER
☐ job	STRING
☐ marital	STRING
☐ education	STRING
☐ default	BOOLEAN
☐ balance	INTEGER
☐ housing	BOOLEAN
☐ loan	BOOLEAN
☐ contact	STRING
☐ day	INTEGER
☐ month	STRING
☐ duration	INTEGER
☐ campaign	INTEGER
☐ pdays	INTEGER
☐ previous	INTEGER
☐ poutcome	STRING
☐ deposit	BOOLEAN

3.2. Atsitiktinio skaičiaus stulpelio pridėjimas

Kadangi pradiniam faile duomenys buvo išdėstyti iš eilės pagal deposit reikšmę – pirmoje pusėje buvo tik yes, o antroje – tik no, toks išdėstymas nesudarytų atsitiktinio pasiskirstymo treniravimo ir testavimo rinkiniams dalijant duomenis (80/20 principu):

Job information Results Chart JSON Execution details Execution graph											
Row	oan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit	
1	alse	cellular	1	apr	351	3	-1	0	unknown	true	
2	alse	cellular	2	apr	739	2	-1	0	unknown	true	
3	rue	cellular	2	apr	243	3	-1	0	unknown	true	
4	alse	cellular	2	apr	397	2	-1	0	unknown	true	
5	alse	telephone	6	apr	1353	2	138	2	success	true	
6	rue	cellular	7	apr	104	2	-1	0	unknown	true	
7	alse	telephone	8	apr	236	1	-1	0	unknown	true	
8	alse	cellular	8	apr	209	1	-1	0	unknown	true	
9	alse	cellular	8	apr	1665	3	-1	0	unknown	true	
10	rue	cellular	8	apr	142	4	-1	0	unknown	true	
11	alse	cellular	9	apr	214	1	-1	0	unknown	true	
12	alse	cellular	9	apr	179	1	-1	0	unknown	true	
13	alse	cellular	14	apr	344	1	74	2	failure	true	

Pastaba: BigQuery vertes yes/no automatiškai paverčia į *boolean* tipo kintamąjį true/false.

Siekiant išvengti šališkumo, buvo nuspręsta pridėti naują stulpelį rand, kuriame kiekvienai eilutei priskiriama atsitiktinė reikšmė tarp 0 ir 1. Tai leis duomenis tolygiai ir atsitiktinai paskirstyti į treniravimo ir testavimo rinkinius.

SQL užklausa, suformuojanti naują lentelę su papildomu rand stulpeliu, atrodo taip:


```
CREATE OR REPLACE TABLE bank.bank_telemarketing AS
SELECT *, RAND() AS rand
FROM bank.bank_telemarketing;
```

Toliau galima peržiūrėti rezultatus surūšiuojant įrašus pagal rand reikšmę. Tai leidžia vizualiai įsitikinti, jog atsitiktinumas veikia taip, kaip tikėtasi:

Untitled query Run Save Download Share Schedule Open in More											
1 SELECT * 2 FROM bank.bank_telemarketing 3 ORDER BY rand DESC; Query completed											
Query results Save results Open in											
Job information Results Chart JSON Execution details Execution graph											
Row	oan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit	rand
30	alse	cellular	7	jul	404	1	-1	0	unknown	false	0.997221372115...
31	alse	cellular	28	aug	161	4	-1	0	unknown	false	0.997100562082...
32	alse	cellular	3	apr	707	1	302	3	failure	true	0.996940591785...
33	alse	cellular	25	jul	1369	9	-1	0	unknown	true	0.996923035753...
34	alse	unknown	16	may	167	2	-1	0	unknown	false	0.996910019845...
35	rue	cellular	16	jul	815	2	407	3	success	true	0.996800311319...
36	alse	unknown	5	may	579	1	-1	0	unknown	true	0.996653737548...
37	rue	unknown	26	jun	271	1	-1	0	unknown	false	0.996596494087...
38	rue	cellular	12	aug	179	6	-1	0	unknown	false	0.996503438195...
39	alse	cellular	4	may	392	2	91	3	success	true	0.996496278009...
40	alse	cellular	16	apr	691	1	-1	0	unknown	false	0.996367161319...

Results per page: 50 1 - 50 of 11162

Norint įsitikinti, kad tiek treniravimo (≤ 0.8), tiek testavimo (> 0.8) rinkiniuose deposit reikšmės (*true* / *false*) yra paskirstytos tikrai subalansuotai, buvo atlikta jų suvestinė analizė:



The screenshot shows a SQL query interface with a query editor, a 'Run' button, and a 'Save' button. The query is as follows:

```
1 SELECT
2   deposit,
3   COUNT(CASE WHEN rand <= 0.8 THEN 1 END) AS count80,
4   COUNT(CASE WHEN rand > 0.8 THEN 1 END) AS count20
5 FROM bank.bank_telemarketing
6 GROUP BY deposit;
```

Below the query editor, a status bar indicates 'Query completed'. The 'Query results' section shows a table with the following data:

Row	deposit	count80	count20
1	true	4151	1138
2	false	4723	1150

80% duomenų ($\text{rand} \leq 0.8$) turėjo:

- true - 4151 įrašų
- false - 4723 įrašai

20% duomenų ($\text{rand} > 0.8$) turėjo:

- true – 1138 įrašų
- false – 1150 įrašų

Kaip matyti, tiek treniravimo, tiek testavimo duomenyse klasės yra beveik idealiai subalansuotos, todėl papildomo balansavimo metodo, treniruojant modelį (pvz.: `auto_class_weights = TRUE`), šiuo atveju naudoti neprisireiks.

4. EKSPERIMENTINIS MODELIŲ TRENIRAVIMAS IR DUOMENŲ

TRANSFORMACIJŲ ĮTAKA

Šiame skyriuje bus atliekamas pradinis modelių treniravimas su skirtingais duomenų variantais, siekiant įvertinti, kaip įvairios transformacijos daro įtaką klasifikavimo modelio tikslumui, precizijai bei kitoms vertinimo metrikoms.

Iš pradžių sukuriamas bazinis modelis, naudojant neapdorotus duomenis, o vėliau palaipsniui analizuojama, kaip keičiasi rezultatai modifikuojant tam tikrus kintamuosius. Tokiu būdu siekiama nustatyti, kurie požymiai turi didžiausią įtaką prognozavimo tikslumui ir kokios duomenų paruošimo strategijos labiausiai pasiteisina. Atlikus šiuos eksperimentus, bus pasirinktas galutinis, geriausiai pasirodęs modelis tolimesniam naudojimui.

4.1. Pradinis modelio treniravimas naudojant neapdorotus duomenis

Pirmojo eksperimento tikslas – sukurti **bazinį modelį**, kuris bus naudojamas kaip atskaitos taškas vėlesniems palyginimams. Šis modelis treniruojamas naudojant pradinis, duomenis, siekiant įvertinti, kaip vėliau taikomi patobulinimai ir transformacijos paveiks klasifikavimo rezultatų tikslumą.

Modelis buvo sukurtas naudojant šią SQL užklausą:

```
CREATE OR REPLACE MODEL `bank.telemarketing_model_v1`  
OPTIONS (  
  model_type = 'LOGISTIC_REG',  
  data_split_method = 'NO_SPLIT',  
  enable_global_explain = TRUE,  
  input_label_cols = ['deposit']  
) AS  
SELECT  
  age,  
  job,  
  marital,  
  education,  
  `default` AS unpaid_loan,  
  balance,  
  housing,  
  loan,  
  contact,  
  month,  
  campaign,  
  pdays,  
  previous,  
  poutcome,  
  deposit  
FROM  
  `bank.bank_telemarketing`  
WHERE  
  rand <= 0.8;
```

Modelio nustatymų (angl. “options”) paaiškinimas:

- `model_type = 'LOGISTIC_REG'` - pasirinktas logistinės regresijos modelis, nes tai klasikinis algoritmas dvejetainiam klasifikavimui;
- `data_split_method = 'NO_SPLIT'` – automatinis duomenų padalijimas BigQuery ML viduje buvo išjungtas, nes jau rankiniu būdu tai darome su *rand* kintamuoju;
- `enable_global_explain = TRUE` - įjungta galimybė matyti kurie požymiai labiausiai įtakoja modelio sprendimą;
- `input_label_cols = ['deposit']` – nurodome, kad mūsų prognozuojamas (priklausomas) kintamasis yra *deposit*.

Nebuvo įtraukti:

- *duration*, nes tai trukmė po įvykusio skambučio – realybėje, prieš skambinant, jos nežinome;
- *day*, nes tai labiau laikinas triukšmas, o ne esminis požymis;
- *rand*, nes jis skirtas tik treniravimo duomenų filtravimui.

Pastaba: laukelis *default*, kuris yra SQL rezervuotas žodis, buvo pervadintas į *unpaid_loan* naudojant ``default` AS unpaid_loan`, kad modelis nemestų SQL sintaksės klaidų.

Treniravimo imtis:

Modelis treniruojamas su 80 % duomenų, t.y., tais įrašais, kuriems `rand <= 0.8`. Likę 20 % (`rand > 0.8`) duomenų bus pasitelkti modelio vertinimui ir testavimui (prognozavimui) vėlesniuose etapuose (ML.EVALUATE ir ML.PREDICT).

Modelio įvertinimo metrikos

Po modelio sukūrimo, BigQuery ML automatiškai pateikia įvairias vertinimo metrikas:

telemarketing_model_v1

Details

Training

Evaluation




Interpretability

Aggregate metrics ⓘ

Threshold ⓘ	0.5000
Precision ⓘ	0.7750
Recall ⓘ	0.5360
Accuracy ⓘ	0.7102
F1 score ⓘ	0.6337
Log loss ⓘ	0.5712
ROC AUC ⓘ	0.7659

- Precision (0.7750) - kiek iš visų teigiamų prognozių buvo teisingos (t. y., tikrieji “yes”).
- Recall (0.5360) - kiek iš visų tikrųjų “yes” atvejų modelis sugebėjo atpažinti.
- Accuracy (0.7102) - bendras teisingų prognozių santykis.
- F1 score (0.6337) - harmoningas precision ir recall vidurkis.
- Log loss (0.5712) - kuo mažesnė vertė – tuo geresnis pasitikėjimas klasifikacija.
- ROC AUC (0.7659) - kuo arčiau 1, tuo geriau atskiria “yes” ir “no”.

Grafinė analizė:



- Precision-recall by threshold: parodo, kaip kinta precision ir recall keičiant sprendimo slenkstį (nuo 0 iki 1). **Svarbus momentas** – sankirtos taškas, kuriame precision ir recall susilygina (čia buvo pasirinktas slenkstis 0.4022).
- Precision-recall curve: rodo kompromisą tarp precision ir recall visame slenkščių diapazone.
- ROC curve: parodo tikrųjų teigiamų (true positive TP) santykį prieš klaidingus teigiamus (false positive FP). Area under curve (AUC) parodo modelio gebėjimą atskirti klases.

Kodėl naudotas sankirtos taškas (threshold 0.4022)?


Šis taškas parodo, kada precision ir recall pasiekia subalansuotą kompromisą, t.y., abu rodikliai yra pakankamai geri. Pasirinkus šį tašką:

Score threshold	
Positive class threshold	0.4022
Positive class	true
Negative class	false
Precision	0.6710
Recall	0.6885
Accuracy	0.6964
F1 score	0.6797

- Precision = 0.6710
- Recall = 0.6885
- Accuracy = 0.6964
- F1 score = 0.6797

Taigi, nors precision sumažėja (daugiau klaidingų teigiamų), recall reikšmingai padidėja (aptinkama daugiau tikrų teigiamų atvejų). Tai ypač aktualu, kai verslui svarbiau “nepraleisti” galimų klientų nei išvengti papildomų skambučių. F1 rodiklio padidėjimas rodo, kad šis kompromisas pagerina bendrą modelio kokybę.

Sumaišymo matrica (angl. “*Confusion matrix*”):



Matome, jog kai klientas iš tikrųjų užsisako terminuotą indėlį (pozityvi klasė), modelis tai teisingai prognozuoja 69% atvejų, o klaidingai - 31% atvejų. Tuo tarpu, kai klientas iš tikrųjų neužsisako indėlio (negatyvi klasė), modelis teisingai prognozuoja 70%, o neteisingai - 30 % atvejų.

Tai rodo, jog modelis abu klasių tipus prognozuoja su panašiu tikslumu, tačiau vis dar egzistuoja reikšminga klaidų tikimybė abiem atvejais

Kintamųjų įtaka modelio prognozėms

Kadangi naudojome `ENABLE_GLOBAL_EXPLAIN = TRUE` parinktį, galima įvertinti, kokią įtaką kiekvienas kintamasis turi modelio prognozėms “*Interpretability*” skiltyje. Ši analizė leidžia suprasti, kurie požymiai labiausiai lemia, ar klientas tikėtina užsisakys terminuotą indėlį.

Toliau pateikiami požymiai, surikiuoti pagal jų reikšmę modelio prognozėse (angl. “*feature attribution*”). Kuo aukštesnė reikšmė, tuo didesnę įtaką tas požymis turėjo galutiniam modelio sprendimui:

telemarketing_model_v1	
Details	Training
Evaluation	Interpretability
Feature Name	Attribution
month	0.396
contact	0.316
poutcome	0.312
housing	0.212
marital	0.157
job	0.138
campaign	0.131
loan	0.086
education	0.083
pdays	0.054
balance	0.048
previous	0.044
unpaid_loan	0.021
age	0.005

Išvalgos:

- *Month, contact, poutcome, housing, marital, job, campaign* yra vieni iš svarbiausių kintamųjų (požymių), turintys gan nemažą įtaką sprendimui.
- Likusieji kintamieji: *loan, education, pdays, balance, previous, unpaid_loan* bei ypač *age* – turėjo gerokai mažesnę svorį prognozėms, kas gali reikšti, kad jie yra mažiau informatyvūs dabartinio modelio kontekste

Tolimesni žingsniai

Atsižvelgiant į mažą kai kurių požymių įtaką, galima pradėti svarstyti šiuos veiksmus:

- Pašalinti ar transformuoti silpnai reikšmingus kintamuosius (pvz.: *age, balance*);
- Sujungti kategorijas arba supaprastinti požymius (pvz.: ankstesnių kampanijų duomenis į vieną kategoriją bandyti sutraukti ar pan.)
- Sukurti naują modelio versiją (*telemarketing_model_v2*) ir palyginti jos rezultatus su esamu modeliu.

4.2. Kintamojo “age” reikšmės vertinimas

Kaip ir prieš tai mateme, *age* kintamasis turi vos **0.005** itaka *deposit* prognozei, tada galime bandyti tai patobulinti arba, jei tobulinimas neapdės – kintamojo nenaudoti modelio kurime.

Transformavimas į kategorijas

Kadangi *age* yra skaitinis požymis, jis buvo suskirstytas į tris kategorijas:

- *young* – amžius mažesnis nei 33 m.,
- *middle-aged* – nuo 33 iki 47 m.,
- *senior* – daugiau nei 47 m.

```
CREATE OR REPLACE MODEL `bank.telemarketing_model_v2`  
OPTIONS (  
  model_type = 'LOGISTIC_REG',  
  data_split_method = 'NO_SPLIT',  
  enable_global_explain = TRUE,  
  input_label_cols = ['deposit']  
) AS  
SELECT  
  CASE  
    WHEN age < 33 THEN 'young'  
    WHEN age BETWEEN 33 AND 47 THEN 'middle-aged'  
    ELSE 'senior'  
  END AS age_group,  
  job,  
  marital,  
  education,  
  'default' AS unpaid_loan,  
  balance,  
  housing,  
  loan,  
  contact,  
  month,  
  campaign,  
  pdays,  
  previous,  
  poutcome,  
  deposit  
FROM  
  `bank.bank_telemarketing`  
WHERE  
  rand <= 0.8;
```

Vietoje skaitinio *age* kintamojo modelyje naudotas naujas *age_group* kintamasis.

Metrikų bei įtakų palyginimas:

telemarketing_model_v1			telemarketing_model_v2		
Details	Training	Evaluation	Details	Training	Evaluation
Explainable AI provides a way of explaining prediction on a per example basis, providing insights into the model's decision-making process.			Explainable AI provides a way of explaining prediction on a per example basis, providing insights into the model's decision-making process.		
Feature Name	Attribution		Feature Name	Attribution	
month	0.396		month	0.339	
contact	0.316		poutcome	0.255	
poutcome	0.312		contact	0.249	
housing	0.212		housing	0.219	
marital	0.157		job	0.131	
job	0.138		marital	0.127	
campaign	0.131		campaign	0.108	
loan	0.086		age_group	0.09	
education	0.083		loan	0.084	
pdays	0.054		education	0.079	
balance	0.048		pdays	0.06	
previous	0.044		previous	0.05	
unpaid_loan	0.021		balance	0.046	
age	0.005		unpaid_loan	0.02	

Matome, kad svoris modelio prognozėms pakilo labai ženkliai, iš 0.005 iki 0.090!

Metrikų pokyčiai:

telemarketing_model_v1				telemarketing_model_v2			
tails	Training	Evaluation	Interpretability	tails	Training	Evaluation	Interpretability
Aggregate metrics ⓘ				Aggregate metrics ⓘ			
Threshold ⓘ				Threshold ⓘ			
0.5000				0.5000			
Precision ⓘ				Precision ⓘ			
0.7750				0.7663			
Recall ⓘ				Recall ⓘ			
0.5360				0.5435			
Accuracy ⓘ				Accuracy ⓘ			
0.7102				0.7089			
F1 score ⓘ				F1 score ⓘ			
0.6337				0.6359			
Log loss ⓘ				Log loss ⓘ			
0.5712				0.5736			
ROC AUC ⓘ				ROC AUC ⓘ			
0.7659				0.7647			

- Nedidelis *precision* sumažėjimas
- Nedidelis *recall* padidėjimas
- *Accuracy* beveik nepakito
- *F1 score* – nežymus padidėjimas
- Nedidelis *log loss* padidėjimas
- *ROC AUC* – šiek tiek sumažėjo

Bendrai vertinant, modelio kokybė reikšmingai **nepakito**, todėl tikslinga ištirti ir kitą scenarijų - modelį be *age* kintamojo, v3.

telemarketing_model_v1				telemarketing_model_v3			
tails	Training	Evaluation	Interpretability	tails	Training	Evaluation	Interpretability
Aggregate metrics ⓘ				Aggregate metrics ⓘ			
Threshold ⓘ				Threshold ⓘ			
0.5000				0.5000			
Precision ⓘ				Precision ⓘ			
0.7750				0.7754			
Recall ⓘ				Recall ⓘ			
0.5360				0.5365			
Accuracy ⓘ				Accuracy ⓘ			
0.7102				0.7105			
F1 score ⓘ				F1 score ⓘ			
0.6337				0.6342			
Log loss ⓘ				Log loss ⓘ			
0.5712				0.5711			
ROC AUC ⓘ				ROC AUC ⓘ			
0.7659				0.7659			

Modelyje visiškai pašalinus *age* kintamąjį, metrikos liko beveik nepakitusios, netgi priešingai – keliomis tūkstantosiomis pagerejo. Tai rodo, kad *age* reikšmė modelio tikslumui yra nežymi ir gali būti pagrįstai pašalinta. Likusiej modelio variantai (v4, v5, v6 ir t.t.) jau bus daromi be *age* kintamojo.

4.3. Kintamojo “default” reikšmės vertinimas

Kitas kintamasis, turėjęs nedidelę įtaką prognozėms, yra *unpaid_loan* (pervadintas iš *default*), kurio svoris siekė vos **0.021** – tai reiškia, kad šis požymis sudarė tik apie 2.1% bendro sprendimo svorio.

Šis požymis žymi, ar klientas turi neapmokėtą paskolą. Galimos dvi reikšmės: *true* arba *false*.

```
SELECT
  `default` AS unpaid_loan,
  COUNT(*) AS count
FROM
  `bank.bank_telemarketing`
WHERE
  rand <= 0.8
GROUP BY
  `default`
ORDER BY
  `default`;
```

Query completed

Query results

	unpaid_loan	count
1	false	8743
2	true	131

Matome, jog duomenų pasiskirstymas labai netolygus:

- Neturi paskolos: 8743 klientai
- Turi paskolą: 131 klientas

Dėl tokios disproporcijos šis kintamasis greičiausiai nepadeda modeliui reikšmingai pagerinti prognozių. Todėl suformuotas naujas modelis (v4), kuriame *default* kintamasis visiškai pašalintas (kartu su anksčiau jau pašalintu *age*), ir rezultatai palyginti su v3 modeliu:

telemarketing_model_v3				telemarketing_model_v4			
tails	Training	Evaluation	Interp	tails	Training	Evaluation	Interp
Aggregate metrics ?				Aggregate metrics ?			
Threshold ?	0.5000			Threshold ?	0.5000		
Precision ?	0.7754			Precision ?	0.7329		
Recall ?	0.5365			Recall ?	0.6001		
Accuracy ?	0.7105			Accuracy ?	0.7106		
F1 score ?	0.6342			F1 score ?	0.6599		
Log loss ?	0.5711			Log loss ?	0.5730		
ROC AUC ?	0.7659			ROC AUC ?	0.7639		

- *precision* sumažėjimas
- *recall* padidėjimas
- *Accuracy* beveik nepakito
- *F1 score* mažas padidėjimas
- *log loss* – beveik nepakito
- *ROC AUC* – beveik nepakito

Pašalinus *default* kintamąjį, modelio *recall* reikšmingai pagerėjo, o *F1* rodiklis taip pat šiek tiek išaugo. Nors *precision* šiek tiek sumažėjo, tokio tipo užduotyje dažnai svarbiau padidinti *recall*, kad būtų identifikuoti kuo daugiau potencialiai teigiamų klientų (t.y. tie, kurie atsakytų “taip” į pasiūlymą dėl terminuoto indėlio).

Modelio tikslumas (*accuracy*), *log loss* bei *ROC AUC* beveik nepasikeitė, todėl galima daryti išvadą, kad *default* kintamasis neteikė reikšmingos vertės prognozėms bei galime, tolimesniuose modeliuose, šio kintamojo nenaudoti. Likusiej modelio variantai (v5, v6, v7 ir t.t.) jau bus daromi be ir be *age* ir be *default* kintamųjų.

4.4. Kintamojo “*balance*” reikšmės vertinimas

Po 4 etapų (skirtingų modelių treniravimo) matome tuos pačius lyderius galutinio rezultato atspejimo itakai bei tuos, kurie vertės beveik neprisideda:

telemarketing_model_v4

Details	Training	Evaluation
Overall: Not explainable prediction		
Feature Name	Attribution	
month	0.336	
contact	0.257	
poutcome	0.245	
housing	0.223	
marital	0.139	
job	0.129	
campaign	0.109	
loan	0.092	
education	0.075	
pdays	0.058	
previous	0.049	
balance	0.046	

Todėl toliau galime dirbti ties modelio tobulinimo, šiuo atveju – *balance*, vidutinio metinio likučio, kintamuoju, kurio pridėtinė vertė kol kas yra menka – vos 0.046..

Transformavimas į kategorijas

Kadangi tai skaitinis požymis, galima pabandyti pagerinti modelio gebėjimą jį interpretuoti, suskirstant *balance* į kategorines reikšmes pagal reikšmių intervalus:

- *Very low* – mažiau nei 0;
- *Low* – tarp 0 ir 1000;
- *Lower-middle* – tarp 1000 ir 5000;
- *Middle* – tarp 5000 ir 10000;
- *Upper-Middle* – tarp 10000 ir 25000
- *High* – daugiau nei 25000

```

CREATE OR REPLACE MODEL 'bank.telemarketing_model_v5'
OPTIONS (
  model_type = 'LOGISTIC_REG',
  data_split_method = 'NO_SPLIT',
  enable_global_explain = TRUE,
  input_label_cols = ['deposit']
) AS
SELECT
  job,
  marital,
  education,
  CASE
    WHEN balance < 0 THEN 'Very Low'
    WHEN balance <= 1000 THEN 'Low'
    WHEN balance <= 5000 THEN 'Lower-Middle'
    WHEN balance <= 10000 THEN 'Middle'
    WHEN balance <= 25000 THEN 'Upper-Middle'
    ELSE 'High'
  END AS balance_category,
  housing,
  loan,
  contact,
  month,
  campaign,
  pdays,
  previous,
  poutcome,
  deposit
FROM
  'bank.bank_telemarketing'
WHERE
  rand <= 0.8;

```

Vietoje skaitinio *balance* kintamojo modelyje naudotas naujas *balance_category* kintamasis.

Metrikų bei įtakų palyginimas

telemarketing_model_v4	telemarketing_model_v5																																																				
Details Training Evaluation	Details Training Evaluation																																																				
Explainable AI Explainable AI provides a way of explain prediction on a per example basis, please	Explainable AI Explainable AI provides a way of explaining prediction on a per example basis, please																																																				
<table> <thead> <tr> <th>Feature Name</th><th>Attribution</th></tr> </thead> <tbody> <tr><td>month</td><td>0.336</td></tr> <tr><td>contact</td><td>0.257</td></tr> <tr><td>poutcome</td><td>0.245</td></tr> <tr><td>housing</td><td>0.223</td></tr> <tr><td>marital</td><td>0.139</td></tr> <tr><td>job</td><td>0.129</td></tr> <tr><td>campaign</td><td>0.109</td></tr> <tr><td>loan</td><td>0.092</td></tr> <tr><td>education</td><td>0.075</td></tr> <tr><td>pdays</td><td>0.058</td></tr> <tr><td>previous</td><td>0.049</td></tr> <tr><td>balance</td><td>0.046</td></tr> </tbody> </table>	Feature Name	Attribution	month	0.336	contact	0.257	poutcome	0.245	housing	0.223	marital	0.139	job	0.129	campaign	0.109	loan	0.092	education	0.075	pdays	0.058	previous	0.049	balance	0.046	<table> <thead> <tr> <th>Feature Name</th><th>Attribution</th></tr> </thead> <tbody> <tr><td>month</td><td>0.388</td></tr> <tr><td>contact</td><td>0.318</td></tr> <tr><td>poutcome</td><td>0.312</td></tr> <tr><td>housing</td><td>0.209</td></tr> <tr><td>marital</td><td>0.162</td></tr> <tr><td>balance_category</td><td>0.161</td></tr> <tr><td>job</td><td>0.136</td></tr> <tr><td>campaign</td><td>0.129</td></tr> <tr><td>education</td><td>0.081</td></tr> <tr><td>loan</td><td>0.08</td></tr> <tr><td>pdays</td><td>0.055</td></tr> <tr><td>previous</td><td>0.043</td></tr> </tbody> </table>	Feature Name	Attribution	month	0.388	contact	0.318	poutcome	0.312	housing	0.209	marital	0.162	balance_category	0.161	job	0.136	campaign	0.129	education	0.081	loan	0.08	pdays	0.055	previous	0.043
Feature Name	Attribution																																																				
month	0.336																																																				
contact	0.257																																																				
poutcome	0.245																																																				
housing	0.223																																																				
marital	0.139																																																				
job	0.129																																																				
campaign	0.109																																																				
loan	0.092																																																				
education	0.075																																																				
pdays	0.058																																																				
previous	0.049																																																				
balance	0.046																																																				
Feature Name	Attribution																																																				
month	0.388																																																				
contact	0.318																																																				
poutcome	0.312																																																				
housing	0.209																																																				
marital	0.162																																																				
balance_category	0.161																																																				
job	0.136																																																				
campaign	0.129																																																				
education	0.081																																																				
loan	0.08																																																				
pdays	0.055																																																				
previous	0.043																																																				

Matome, kad svoris modelio prognozėms pakilo ženkliai, iš 0.046 iki 0.161!

Metrikų pokyčiai:

telemarketing_model_v4				telemarketing_model_v5			
tails	Training	Evaluation	Interpretability	tails	Training	Evaluation	Interpretability
Aggregate metrics ⓘ				Aggregate metrics ⓘ			
Threshold ⓘ 0.5000				Threshold ⓘ 0.5000			
Precision ⓘ 0.7329				Precision ⓘ 0.7729			
Recall ⓘ 0.6001				Recall ⓘ 0.5394			
Accuracy ⓘ 0.7106				Accuracy ⓘ 0.7104			
F1 score ⓘ 0.6599				F1 score ⓘ 0.6354			
Log loss ⓘ 0.5730				Log loss ⓘ 0.5697			
ROC AUC ⓘ 0.7639				ROC AUC ⓘ 0.7685			

- *precision* Padidėjimas
- *recall* sumažėjimas
- *Accuracy* nepakito
- *F1 score* – pamažėjimas
- Nedidelis *log loss* pamažėjimas
- *ROC AUC* – šiek tiek padidėjo

Bendrai vertinant, nors balance kintamojo sugrupavimas į kategorijas padidino jo svarbą modelyje (*attribution* išaugo nuo 0.046 iki 0.161), bendras modelio našumas reikšmingai nepagerėjo. Kai kurios metrikos, kaip *precision* ir *ROC AUC*, pagerėjo, tačiau kitos – tokios kaip *recall* ir *F1 score* – pablogėjo, o *accuracy* išliko nepakitusi.

Atsižvelgiant į tai, kad balance (ar jo kategorinė forma *balance_category*) vis tiek nėra tarp svarbiausių modelio kintamųjų, galima svarstyti apie dar vieną eksperimentą – visiškai pašalinti šį kintamąjį iš modelio. Tai gali padėti supaprastinti modelį, išlaikant panašų tikslumo lygį, tačiau dirbant tik su reikšmingiausiais kintamaisiais. Paprastesnis modelis gali būti ne tik efektyvesnis, bet ir geriau interpretuojamas, jį pavadinsime v6:

telemarketing_model_v4				telemarketing_model_v6			
tails	Training	Evaluation	Interpretability	tails	Training	Evaluation	Interpretability
Aggregate metrics ⓘ				Aggregate metrics ⓘ			
Threshold ⓘ 0.5000				Threshold ⓘ 0.5000			
Precision ⓘ 0.7329				Precision ⓘ 0.7297			
Recall ⓘ 0.6001				Recall ⓘ 0.6011			
Accuracy ⓘ 0.7106				Accuracy ⓘ 0.7093			
F1 score ⓘ 0.6599				F1 score ⓘ 0.6592			
Log loss ⓘ 0.5730				Log loss ⓘ 0.5738			
ROC AUC ⓘ 0.7639				ROC AUC ⓘ 0.7626			

Kaip matome, metrikos išliko beveik identiškos. Tai patvirtina, kad balance reikšmė modelio našumui yra labai nedidelė, ir jo galima pagrįstai atsisakyti. Tolesniuose modelių variantuose (pvz. v7 ir toliau) šis kintamasis nebus naudojamas, kad būtų užtikrintas modelio paprastumas ir treniravimo efektyvumas.

4.5. Kintamųjų “previous” ir “pdays” reikšmių vertinimas

Kadangi abu kintamieji susiję su praeities duomenimis bei jų abiejų svoriai yra gan maži, atitinkamai 0.049 bei 0.058, galime pabandyti atlikti šiems duomenims transformacijas

telemarketing_model_v6

Details	Training	Evaluation
---------	----------	------------

Explainable AI

Explainable AI provides a way of explain run ML.EXPLAIN_PREDICT or ML.EXPLAIN_PREDICT

Feature Name	Attribution
month	0.338
contact	0.256
poutcome	0.245
housing	0.226
marital	0.138
job	0.13
campaign	0.109
loan	0.095
education	0.078
pdays	0.058
previous	0.049

Kintamasis **previous** nurodo, kiek kartų klientui buvo skambinta ankstesnėse kampanijose. Reikšmė 0 reiškia, kad nebuvo skambinta, o bet kuri reikšmė virš 0 – kad kontaktas vyko (atitinkamai tiek kartų). Šią informaciją galima supaprastinti suskirstant į dvinaires reikšmes: **0 – neskambinta, 1 – skambinta**.

Kintamasis **pdays** nurodo, kiek dienų praėjo nuo paskutinio kontakto. Jei reikšmė -1, tai reiškia, kad klientui niekada nebuvo skambinta. Visos kitos reikšmės yra teigiamos ir nurodo konkrečią dienų skaičių nuo paskutinio kontakto. Šį kintamąjį taip pat galima supaprastinti į dvinaires reikšmes: **0 – nesusisiektas, 1 – susisiektas**.

Kadangi abu kintamieji iš esmės aprašo tą pačią sąvoką – ar buvo anksčiau kontaktuota, atlikta analizė siekiant nustatyti jų tarpusavio priklausomybę. Buvo suskaičiuota, kiek kartų pdays yra 0 ir bei tuo pačiu metu previous yra 0 ir 1.

Reikšmių kiekio skaičiavimas:

```
1 SELECT
2   COUNT(CASE WHEN pdays = -1 THEN 1 END) AS count_pdays_0,
3   COUNT(CASE WHEN pdays != -1 THEN 1 END) AS count_pdays_1,
4   COUNT(CASE WHEN previous = 0 THEN 1 END) AS count_previous_0,
5   COUNT(CASE WHEN previous != 0 THEN 1 END) AS count_previous_1
6 FROM 'bank.bank_telemarketing'
7 WHERE rand <= 0.8;
```

Query completed

Query results

Job information	Results	Chart	JSON	Execution details	Execution graph
	count_pdays_0 ▾	count_pdays_1 ▾	count_previous_0 ▾	count_previous_1 ▾	
1	6598	2276	6598	2276	

- Kai niekada nebuvo susisieکتa – tokių klientų yra 6598, o kai buvo – 2279;
 - Kai nebuvo jokių ankstesnių skambučių – taip pat yra 6598 klientai, kai buvo – 2279.
- Šie duomenys patvirtina hipotezę, kad kintamieji *pdays* ir *previous* visais atvejais sutampa pagal loginę reikšmę ir todėl gali būti sujungti į vieną bendrą kintamąjį. Sukurtas naujas kintamasis *pContact_combined*, kuris įgauna reikšmę:

- 0, jei *pdays* = -1 ir *previous* = 0
- 1, jei *pdays* != -1 ir *previous* > 0

Kiti deriniai (pvz., *pdays* = -1, bet *previous* > 0) yra traktuojami kaip išimtys ir jiems priskiriama reikšmė NULL

```
1 CREATE OR REPLACE MODEL 'bank.telemarketing_model_v7'
2 OPTIONS (
3   model_type = 'LOGISTIC_REG',
4   data_split_method = 'NO_SPLIT',
5   enable_global_explain = TRUE,
6   input_label_cols = ['deposit']
7 ) AS
8 SELECT
9   job,
10  marital,
11  education,
12  housing,
13  loan,
14  contact,
15  month,
16  campaign,
17  CASE
18    WHEN pdays = -1 AND previous = 0 THEN 0
19    WHEN pdays != -1 AND previous > 0 THEN 1
20    ELSE NULL
21  END AS pContact_combined,
22  outcome,
23  deposit
24 FROM
25   'bank.bank_telemarketing'
26 WHERE
27   rand <= 0.8;
```

Query completed

Query results

Job information Results Execution details Execution graph

Successfully created model named telemarketing_model_v7.

Atlikus treniravimą galime pastebėti svorio įtaką galutiniam rezultatui:

telemarketing_model_v7	
Details	Training
Evaluation	
Explainable AI Explainable AI provides a way of explain prediction on a per example basis, please	
Feature Name	Attribution
month	0.335
contact	0.253
poutcome	0.233
housing	0.222
pContact_combined	0.152
marital	0.139
job	0.129
campaign	0.106
loan	0.094
education	0.076

Atlikus treniravimą su *pContact_combined* vietoje atskirų *pdays* ir *previous*, pastebėta, kad šio naujo kintamojo svarba modelyje (**0.152**) žymiai išaugo, palyginus su buvusiomis reikšmėmis. Tai rodo, kad modelis dabar aiškiau identifikuoja reikšmingą informaciją apie ankstesnį kontaktą per supaprastintą ir labiau informatyvų kintamąjį.

Galime pereiti prie metrikų palyginimo tarp v6 ir v7 modelio:

telemarketing_model_v6

telemarketing_model_v7

Details

Training

Evaluation

Interpretability

Details

Training

Evaluation

Interpretability

Aggregate metrics ?

Aggregate metrics ?

Threshold ?0.5000

Threshold ?0.5000

Precision ?0.7297

Precision ?0.7336

Recall ?0.6011

Recall ?0.5962

Accuracy ?0.7093

Accuracy ?0.7098

F1 score ?0.6592

F1 score ?0.6578

Log loss ?0.5738

Log loss ?0.5737

ROC AUC ?0.7626

ROC AUC ?0.7620

Iš esmės nelabai kas ir pasikeitė, bet modelis tapo supaprastintas, aiškesnis, ir sumažintas vienu kintamuoju. Tokia modifikacija yra pagrįsta ir bus naudojama tolimesnių modelių versijose (v8, v9 ir t.t.).

4.6. Kintamojo “education” reikšmės vertinimas

Kintamasis *education* nurodo kliento išsilavinimo lygį. Kadangi tai yra kategorinis kintamasis ir išsilavinimo kategorijų kiekis nėra didelis, jų papildomas apdorojimas ar retų reikšmių filtravimas nėra būtinas. Tačiau, siekiant įvertinti šio kintamojo reikšmingumą modelio rezultatams, buvo nuspręsta laikinai pašalinti *education* iš treniravimo duomenų ir sukurti naują v8 modelį:

telemarketing_model_v7				telemarketing_model_v8			
tails	Training	Evaluation	Interpretability	tails	Training	Evaluation	Interpretability
Aggregate metrics ⓘ				Aggregate metrics ⓘ			
Threshold ⓘ 0.5000				Threshold ⓘ 0.5000			
Precision ⓘ 0.7336				Precision ⓘ 0.7333			
Recall ⓘ 0.5962				Recall ⓘ 0.5955			
Accuracy ⓘ 0.7098				Accuracy ⓘ 0.7095			
F1 score ⓘ 0.6578				F1 score ⓘ 0.6573			
Log loss ⓘ 0.5737				Log loss ⓘ 0.5744			
ROC AUC ⓘ 0.7620				ROC AUC ⓘ 0.7612			

Modelio metrikos iš esmės nepasikeitė, lyginant su ankstesne versija, kurioje *education* kintamasis buvo įtrauktas. Tai rodo, kad šis kintamasis neturi reikšmingos įtakos modelio sprendimams, todėl jo pašalinimas yra pagrįstas. Tolesniuose modelio tobulinimo etapuose (v9, v10 ir t.t.) *education* nebus įtrauktas į treniravimo duomenis.

4.7. Kintamojo “loan” reikšmės vertinimas

Kintamasis *loan* nurodo, ar klientas turi asmeninę paskolą. Tai dvejetainis kintamasis, turintis dvi galimas reikšmes: „yes“ (turi paskolą) ir „no“ (neturi paskolos). Kadangi kintamasis yra jau sugrupuotas ir neturi papildomų reikšmių, papildomos transformacijos nėra prasmingos.

Norint įvertinti šio kintamojo įtaką modeliui, buvo suformuotas naujas modelis v9, kuriame *loan* kintamasis buvo pašalintas iš treniravimo duomenų. Palyginame su v8:

telemarketing_model_v8				telemarketing_model_v9			
tails	Training	Evaluation	Interpretability	tails	Training	Evaluation	Interpretability
Aggregate metrics ⓘ				Aggregate metrics ⓘ			
Threshold ⓘ 0.5000				Threshold ⓘ 0.5000			
Precision ⓘ 0.7333				Precision ⓘ 0.7175			
Recall ⓘ 0.5955				Recall ⓘ 0.6008			
Accuracy ⓘ 0.7095				Accuracy ⓘ 0.7026			
F1 score ⓘ 0.6573				F1 score ⓘ 0.6540			
Log loss ⓘ 0.5744				Log loss ⓘ 0.5763			
ROC AUC ⓘ 0.7612				ROC AUC ⓘ 0.7587			

Lyginant modelį v9 su ankstesne versija, galima pastebėti, kad:

- Precision sumažėjo, tačiau
- Recall šiek tiek padidėjo.

Nepaisant šių nežymių pokyčių, bendros metrikos rodo, kad loan kintamasis neturi reikšmingos įtakos modelio kokybei. Todėl priimtas sprendimas neįtraukti loan kintamojo į treniravimo duomenis ateities modelių versijose (v10, v11 ir t.t.).

4.8. Kintamojo “campaign” reikšmės vertinimas

Kintamasis campaign nurodo, kiek kartų klientui buvo skambinta per šią marketingo kampaniją. Reikšmė 1 reiškia, kad tai pirmasis skambutis (ankstesnių nebuvo), o reikšmės, didesnės už 1, reiškia, kad klientui buvo skambinta jau anksčiau. Atsižvelgiant į tai, nuspręsta šį kintamąjį transformuoti į dvejetainį formatą – campaign_binary, kur:

- 0 reiškia, kad skambinta pirmą kartą,
- 1 – kad skambinta pakartotinai.

Šią transformaciją atlikus, sukurtas modelis *telemarketing_model_v10*, kuris lyginamas su ankstesniu *telemarketing_model_v9*:

```
1 CREATE OR REPLACE MODEL 'bank.telemarketing_model_v10'
2 OPTIONS (
3   model_type = 'LOGISTIC_REG',
4   data_split_method = 'NO_SPLIT',
5   enable_global_explain = TRUE,
6   input_label_cols = ['deposit']
7 ) AS
8 SELECT
9   job,
10  marital,
11  housing,
12  contact,
13  month,
14  CASE
15    WHEN campaign = 1 THEN 0
16    WHEN campaign > 1 THEN 1
17    ELSE NULL
18  END AS campaign_binary,
19  CASE
20    WHEN pdays = -1 AND previous = 0 THEN 0
21    WHEN pdays != -1 AND previous > 0 THEN 1
22    ELSE NULL
23  END AS pContact_combined,
24  poutcome,
25  deposit
26 FROM
27   'bank.bank_telemarketing'
28 WHERE
29   rand <= 0.8;
30
```

Query completed

Bei palyginame svorinius įverčius:

telemarketing_model_v9	telemarketing_model_v10																																				
Details Training Evaluation	Details Training Evaluation																																				
Explainable AI Explainable AI provides a way of explaining prediction on a per example basis, please	Explainable AI Explainable AI provides a way of explaining prediction on a per example basis, please																																				
<table><thead><tr><th>Feature Name</th><th>Attribution</th></tr></thead><tbody><tr><td>month</td><td>0.35</td></tr><tr><td>contact</td><td>0.267</td></tr><tr><td>poutcome</td><td>0.24</td></tr><tr><td>housing</td><td>0.23</td></tr><tr><td>pContact_combined</td><td>0.153</td></tr><tr><td>marital</td><td>0.151</td></tr><tr><td>job</td><td>0.135</td></tr><tr><td>campaign</td><td>0.111</td></tr></tbody></table>	Feature Name	Attribution	month	0.35	contact	0.267	poutcome	0.24	housing	0.23	pContact_combined	0.153	marital	0.151	job	0.135	campaign	0.111	<table><thead><tr><th>Feature Name</th><th>Attribution</th></tr></thead><tbody><tr><td>month</td><td>0.35</td></tr><tr><td>contact</td><td>0.27</td></tr><tr><td>poutcome</td><td>0.241</td></tr><tr><td>housing</td><td>0.229</td></tr><tr><td>pContact_combined</td><td>0.156</td></tr><tr><td>marital</td><td>0.152</td></tr><tr><td>campaign_binary</td><td>0.139</td></tr><tr><td>job</td><td>0.137</td></tr></tbody></table>	Feature Name	Attribution	month	0.35	contact	0.27	poutcome	0.241	housing	0.229	pContact_combined	0.156	marital	0.152	campaign_binary	0.139	job	0.137
Feature Name	Attribution																																				
month	0.35																																				
contact	0.267																																				
poutcome	0.24																																				
housing	0.23																																				
pContact_combined	0.153																																				
marital	0.151																																				
job	0.135																																				
campaign	0.111																																				
Feature Name	Attribution																																				
month	0.35																																				
contact	0.27																																				
poutcome	0.241																																				
housing	0.229																																				
pContact_combined	0.156																																				
marital	0.152																																				
campaign_binary	0.139																																				
job	0.137																																				

Matome, kad po transformacijos `campaign_binary` svarba (attribution) modelyje padidėjo nuo 0.111 iki 0.139, tai rodo, kad nauja binarinė forma yra naudingesnė nei originali, galime ir metrikas palyginti:

telemarketing_model_v9	telemarketing_model_v10
Details Training Evaluation Interpretability	Details Training Evaluation Interpretability
Aggregate metrics ⓘ	Aggregate metrics ⓘ
Threshold ⓘ 0.5000	Threshold ⓘ 0.5000
Precision ⓘ 0.7175	Precision ⓘ 0.7223
Recall ⓘ 0.6008	Recall ⓘ 0.5941
Accuracy ⓘ 0.7026	Accuracy ⓘ 0.7033
F1 score ⓘ 0.6540	F1 score ⓘ 0.6519
Log loss ⓘ 0.5763	Log loss ⓘ 0.5780
ROC AUC ⓘ 0.7587	ROC AUC ⓘ 0.7564

Pastebimas nedidelis *precision* padidėjimas ir labai nežymus *recall* sumažėjimas. *F1* reikšmė šiek tiek sumažėja, bet skirtumas yra labai minimalus. Atsižvelgiant į tai, kad `campaign_binary` svarba modelyje padidėjo ir *precision* pagerėjo, nuspręsta naudoti binarinę `campaign` versiją tolesniuose modelio tobulinimo etapuose.

4.9. Likusiųjų kintamųjų vertinimas

Iki šiol iš modelio pašalinome nereikalingus ar nereikšmingus kintamuosius, kai kuriuos transformavome. Po dešimties modelio versijų turime gana stabilius ir svarbius požymius, turinčius didelę įtaką galutiniam rezultatui:

Feature Name	Attribution
month	0.35
contact	0.27
poutcome	0.241
housing	0.229
pContact_combined	0.156
marital	0.152
campaign_binary	0.139
job	0.137

Dabartiniai modelyje likę kintamieji turi pakankamai aukštą reikšmę (*attribution*), todėl esminių pakeitimų daryti nebeplanuojame, bet trumpai įvertinkime kiekvieną jų ir galimas transformacijas, galbūt ir galima kažką atlikti.

job kintamasis

Šis kintamasis nurodo kliento užimamas pareigas. Nors buvo idėja pavienes darbo pozicijas sugrupuoti į vieną “*other*“ kategoriją, tačiau analizė parodė, kad job kintamasis jau turi tik 12 skirtingų reikšmių – tai nedidelis kiekis, o dominuojančios kategorijos išryškintos automatiškai. Todėl papildomos transformacijos nėra būtinos.

```
1 SELECT
2   job,
3   COUNT(*) AS count
4 FROM
5   'bank.bank_telemarketing'
6 WHERE
7   rand <= 0.8
8 GROUP BY
9   job
10 ORDER BY
11   count DESC;
```

Query completed

Query results

job	count
unemployed	291
student	286
entrepreneur	257
housemaid	217
unknown	54

marital kintamasis

Tai kategorinis kintamasis su reikšmėmis kaip *married* (vedęs), *single* (vienišas) ir *divorced* (išsiskyręs). Kadangi reikšmių nedaug ir jos aiškios, transformuoti jo neverta – paliekame tokį, koks yra.

housing kintamasis

Šis kintamasis nurodo, ar klientas turi būsto paskolą. Tai binarinis kintamasis (*yes/no*), todėl papildomos transformacijos nereikalingos. Paliekamas be pokyčių.

poutcome kintamasis

Tai informacija apie ankstesnių marketingo kampanijų rezultatus (*success* / *failure* / *unknown* / *other*). Kadangi tai kategorinis kintamasis su aiškiomis reikšmėmis, jį transformuoti taip pat nėra pagrindo – paliekamas nepakitęs.

contact kintamasis

Kintamasis informuoja apie kontaktavimo būdą – *telephone*, *cellular* arba *unknown*. Tai, vėlgi, kategorinis kintamasis, o reikšmių mažai, todėl transformacijos nėra būtinos.

month kintamasis

Svarbiausias kintamasis, turintis 0.35 svorinį įvertį modelyje. Jis nurodo, kokį mėnesį klientas buvo kontaktuotas. Kadangi tai laiko kintamasis su 12 reikšmių, teoriškai būtų galima jį konvertuoti į skaitmeninį formatą (1-12), bet tai reikšmingos įtakos neturėtų – modeliai vektorizuoja automatiškai. Tačiau galime atlikti papildomą analizę, siekdami sužinoti, **kuriomis mėnesiais klientai dažniausiai sutinka pasirašyti terminuotą indėlį**, o kuriais – ne.

🔍 month count [Run](#) [Save query \(Classic\)](#) [Share](#) [Schedule](#) [Open in](#)


```
1 SELECT
2   month,
3   SUM(CASE WHEN deposit = TRUE THEN 1 ELSE 0 END) AS true_count,
4   SUM(CASE WHEN deposit = FALSE THEN 1 ELSE 0 END) AS false_count,
5   SUM(CASE WHEN deposit = TRUE THEN 1 ELSE 0 END) - SUM(CASE WHEN deposit = FALSE THEN 1 ELSE 0 END) AS
count_difference
6 FROM
7   bank.bank_telemarketing
8 GROUP BY
9   month
10 ORDER BY
11   count_difference ASC;
```

✅ Query completed

Gauta atitinkama lentelė:

Row	month	true_count	false_count	count_difference
1	may	925	1899	-974
2	jul	627	887	-260
3	aug	688	831	-143
4	nov	403	540	-137
5	jun	546	676	-130
6	jan	142	202	-60
7	dec	100	10	90
8	feb	441	335	106
9	sep	269	50	219
10	mar	248	28	220
11	apr	577	346	231
12	oct	323	69	254

Galime viską supaprastinti ir pateikti grafiko pavidalu:



Remiantis grafiku, akivaizdu, kad vasaros mėnesiais – ypač gegužę, liepą ir rugpjūtį – klientams skambinta daugiausiai dėl terminuoto indėlio pasiūlymo. Tačiau šiuo laikotarpiu fiksuojamas didžiausias neigiamas skirtumas tarp užsisakiusių ir ne – pavyzdžiui, gegužę net 1 899 klientai atsisakė, o tik 925 sutiko su pasiūlymu (skirtumas –974). Tai leidžia daryti prielaidą, kad vasarą žmonės yra mažiau linkę priimti finansinius įsipareigojimus – galbūt dėl atostogų, sumažėjusio dėmesio finansiniams pasiūlymams ar kitų prioritetų.

Tuo tarpu pavasarį (ypač balandį) ir rudenį (rugsėį–spalį) stebimas pozityvesnis atsakas. Balandžio mėnesį užsisakiusių skaičius (577) viršija atsisakiusių (346), o skirtumas +231 rodo ženkliai didesnę susidomėjimą. Panaši tendencija matoma ir rugsėį

(+219), spalį (+254), kas leidžia manyti, jog šiais laikotarpiais žmonės aktyviau svarsto galimybę taupyti arba investuoti.

Taip pat išsiskiria gruodžio mėnuo, kurio metu, nors ir atlikta labai mažai skambučių, užfiksuotas teigiamas skirtumas (+90). Tai gali būti susiję su metų pabaigos finansiniu planavimu arba premijų laikotarpiu, kai žmonės disponuoja papildomomis lėšomis.

4.10. Bazinio bei galutinio modelio palyginimas

Per modelio kūrimo ir tobulinimo procesą buvo atlikta reikšminga duomenų inžinerija – pašalinta daug mažai reikšmingų ar modelio kokybei neigiamą įtaką darančių kintamųjų, kai kurie kintamieji buvo transformuoti, suvienodinti ar pertvarkyti. Tai leido pagerinti modelio interpretaciją bei klasifikacijos tikslumą. Galime palyginti bazinį modelį (v1) su galutiniu, optimizuotu modeliu (v10).

Metrikos:

telemarketing_model_v1		telemarketing_model_v10	
tails	Training	tails	Training
Evaluation		Evaluation	
Interpretabil		Interpretal	
Aggregate metrics ?		Aggregate metrics ?	
Threshold ?	0.5000	Threshold ?	0.5000
Precision ?	0.7750	Precision ?	0.7223
Recall ?	0.5360	Recall ?	0.5941
Accuracy ?	0.7102	Accuracy ?	0.7033
F1 score ?	0.6337	F1 score ?	0.6519
Log loss ?	0.5712	Log loss ?	0.5780
ROC AUC ?	0.7659	ROC AUC ?	0.7564

Kaip matome, nors *Precision* šiek tiek sumažėjo, *Recall* reikšmė reikšmingai padidėjo, kas rodo, jog galutinis modelis geriau atpažįsta klientus, kurie iš tikrųjų sutiks atsidaryti indėlį. Dėl šio balanso pagerėjo ir *F1 score* (nuo 0.6337 iki 0.6519), o tai rodo bendrą klasifikacijos kokybės padidėjimą.

Sumaišymo matricos:



Nors pokytis atrodo nedidelis (1 %), tai vis tiek reikšmingas patobulinimas prilausomai nuo darbuotojo poreikių: galutinis modelis geriau atpažįsta klientus, kurie nenori atsidaryti indėlio, o tai itin svarbu siekiant sumažinti bereikalingus kontaktus ir telemarketingo resursų švaistymą.

Kintamųjų įtakos:

telemarketing_model_v1	telemarketing_model_v10																																																
Details Training Evaluation Explainable AI provides a way of explaining overall. For explanationable prediction on <table> <thead> <tr> <th>Feature Name</th><th>Attribution</th></tr> </thead> <tbody> <tr><td>month</td><td>0.396</td></tr> <tr><td>contact</td><td>0.316</td></tr> <tr><td>poutcome</td><td>0.312</td></tr> <tr><td>housing</td><td>0.212</td></tr> <tr><td>marital</td><td>0.157</td></tr> <tr><td>job</td><td>0.138</td></tr> <tr><td>campaign</td><td>0.131</td></tr> <tr><td>loan</td><td>0.086</td></tr> <tr><td>education</td><td>0.083</td></tr> <tr><td>pdays</td><td>0.054</td></tr> <tr><td>balance</td><td>0.048</td></tr> <tr><td>previous</td><td>0.044</td></tr> <tr><td>unpaid_loan</td><td>0.021</td></tr> <tr><td>age</td><td>0.005</td></tr> </tbody> </table>	Feature Name	Attribution	month	0.396	contact	0.316	poutcome	0.312	housing	0.212	marital	0.157	job	0.138	campaign	0.131	loan	0.086	education	0.083	pdays	0.054	balance	0.048	previous	0.044	unpaid_loan	0.021	age	0.005	Details Training Evaluation Explainable AI Explainable AI provides a way of explaining overall. For explanationable prediction on <table> <thead> <tr> <th>Feature Name</th><th>Attribution</th></tr> </thead> <tbody> <tr><td>month</td><td>0.35</td></tr> <tr><td>contact</td><td>0.27</td></tr> <tr><td>poutcome</td><td>0.241</td></tr> <tr><td>housing</td><td>0.229</td></tr> <tr><td>pContact_combined</td><td>0.156</td></tr> <tr><td>marital</td><td>0.152</td></tr> <tr><td>campaign_binary</td><td>0.139</td></tr> <tr><td>job</td><td>0.137</td></tr> </tbody> </table>	Feature Name	Attribution	month	0.35	contact	0.27	poutcome	0.241	housing	0.229	pContact_combined	0.156	marital	0.152	campaign_binary	0.139	job	0.137
Feature Name	Attribution																																																
month	0.396																																																
contact	0.316																																																
poutcome	0.312																																																
housing	0.212																																																
marital	0.157																																																
job	0.138																																																
campaign	0.131																																																
loan	0.086																																																
education	0.083																																																
pdays	0.054																																																
balance	0.048																																																
previous	0.044																																																
unpaid_loan	0.021																																																
age	0.005																																																
Feature Name	Attribution																																																
month	0.35																																																
contact	0.27																																																
poutcome	0.241																																																
housing	0.229																																																
pContact_combined	0.156																																																
marital	0.152																																																
campaign_binary	0.139																																																
job	0.137																																																

V1 modelyje dominavo šie kintamieji: *month*, *contact*, *poutcome*, *housing*, *marital*, *job*, *campaign*...

Bendras kintamųjų skaičius buvo didesnis, tačiau kai kurie, pvz. *age*, *balance*, *previous*, *pdays*, turėjo labai mažą įtaką ir nepadėjo gerinti klasifikacijos kokybės.

V10 modelyje:

- Išsaugoti tik svarbiausi kintamieji;
- Kai kurie sujungti arba pervadinti;
- Sumažintas bendras kintamųjų skaičius, išmesti mažai reikšmingi;
- Pagerintas kintamųjų reprezentavimas.

Tai rodo kryptingą judėjimą link interpretuojamesnio ir efektyvesnio modelio.

Apibendrinimas

Galutinio (v10) modelio rezultatai rodo nuoseklų ir kryptingą tobulinimo procesą: pagerintas *recall* ir *F1 score*, sumažintas kintamųjų skaičius bei padidinta modelio interpretacija. Nors bendras metrikų šuolis nėra drastiškas arba jo visai nėra, tačiau tai – aiškus žingsnis į kokybiškesnį ir tikslingesnį telemarketingo prognozavimo modelį.

5. MODELIO ĮVERTINIMAS

Šiame etape įvertinsime sukurtą klasifikavimo modelį, naudodami duomenų dalį, kuri nebuvo naudota treniravimui – t. y. likusius 20% duomenų. Modelio įvertinimas yra būtinas tam, kad objektyviai patikrintume, kaip gerai modelis generalizuojasi (t.y. kaip jis veikia su nematytais duomenimis). Tai padeda išvengti perteklinio pritaikymo (angl. *overfitting*) bei leidžia palyginti skirtingus modelius tarpusavyje.

ML.EVALUATE yra “BigQuery ML” funkcija, kuri automatiškai apskaičiuoja svarbius klasifikavimo modelio kokybės rodiklius, tokius kaip *accuracy*, *precision*, *recall*, *F1 score*, *log loss*, *ROC AUC* – apie visus iš jų jau buvo kalbėta “4.1. Pradinis modelio treniravimas naudojant neapdorotus duomenis” dalyje.

Modelio įvertinimui naudosime tuos duomenis, kurie nebuvo įtraukti į treniravimą, t. y. likusius 20%. Tokia praktika užtikrina, kad vertinimas būtų nepriklausomas nuo mokymosi duomenų ir atspindėtų realias prognozavimo galimybes.

Naudojamas SQL:

```
evaluate Run More Save query

1 SELECT
2 *
3 FROM
4 ML.EVALUATE (
5   MODEL 'bank.telemarketing_model_v10',
6   (
7     SELECT
8       job,
9       marital,
10      housing,
11      contact,
12      month,
13      CASE
14        WHEN campaign = 1 THEN 0
15        WHEN campaign > 1 THEN 1
16        ELSE NULL
17      END AS campaign_binary,
18      CASE
19        WHEN pdays = -1 AND previous = 0 THEN 0
20        WHEN pdays != -1 AND previous > 0 THEN 1
21        ELSE NULL
22      END AS pContact_combined,
23      poutcome,
24      deposit
25    FROM
26      'bank.bank_telemarketing'
27    WHERE
28      rand > 0.8
29  )
30 );
```

Pastaba: ML.EVALUATE reikalauja, kad įvesties (SELECT) duomenys būtų identiški treniravimo užklausiai, įskaitant visas transformacijas, stulpelių pavadinimus ir tipus!

Gauti pagrindiniai vertinimo metrikos rezultatai

Job information		Results	Chart	JSON	Execution details	Execution graph
Row	precision	recall	accuracy	f1_score	log_loss	roc_auc
1	0.740740740740...	0.579964850615...	0.690122377622...	0.650566781665...	0.583912967707...	0.750995004995...

- *Accuracy* matome, jog modelis teisingai nuspėjo apie 69% visų atvejų (tiek ėmusių terminuotą indėlį, tiek ne);
- *Precision* rodo, kad iš visų prognozuotų TRUE reikšmių, 74.1% buvo teisingos. Kitaip tariant, kai modelis sako TRUE, tai jis gan retai klysta;
- Vertinant *Recall*, modelis teisingai atpažino 58% visų realių TRUE atvejų;
- *F1 score* matome vidurkį tarp *precision* ir *recall* – naudinga, kai reikia balanso vertės tarp judviejų;
- *Log loss* matome, jog modelio tikimybės prognozės nėra tobulos, bet neblogos – 58.4%;
- Na ir *ROC AUC* rezultatai matome parodo, jog modelis gana gerai skirias klaases TRUE ir FALSE


Modelis pasiekė gerą tikslumą ir AUC, o tai reiškia, kad jis geba gana patikimai atskirti klientus, kurie užsakys terminuotą indėlį, nuo tų, kurie to nedarys. Visgi *recall* yra mažesnis, todėl ateityje galėtų būti svarstoma atlikti balansavimą duomenų (pvz. `auto_class_weights = TRUE`), kad modelis atpažintų daugiau realių „TRUE“ atvejų.

6. PROGNOZĖS ATLIKIMAS

Po to, kai modelis buvo sėkmingai ištreniruotas ir įvertintas, galime jį panaudoti prognozėms atlikti su anksčiau nematytais duomenimis. Šiuo atveju naudosime tą pačią duomenų dalį, kuri buvo naudota modelio įvertinimui – t. y. likusius 20% įrašų, kurie nebuvo įtraukti į treniravimo procesą.

ML.PREDICT funkcija „BigQuery ML“ aplinkoje leidžia pritaikyti jau ištreniruotą modelį bet kokiems įvesties duomenims ir gauti prognozes. Ši funkcija grąžina ne tik prognozuotą reikšmę, bet ir tikimybę, kuri leidžia įvertinti prognozės stiprumą.

Naudojamas SQL:



```
predict
Run Save query (Classic)
SELECT
  *
FROM
  ML.PREDICT (
    MODEL `bank.telemarketing_model_v10`,
    (
      SELECT
        job,
        marital,
        housing,
        contact,
        month,
        CASE
          WHEN campaign = 1 THEN 0
          WHEN campaign > 1 THEN 1
          ELSE NULL
        END AS campaign_binary,
        CASE
          WHEN pdays = -1 AND previous = 0 THEN 0
          WHEN pdays != -1 AND previous > 0 THEN 1
          ELSE NULL
        END AS pContact_combined,
        poutcome,
        deposit
      FROM
        `bank.bank_telemarketing`
      WHERE
        rand > 0.8
    )
  );
```

Pastaba: *ML.PREDICT* taip pat reikalauja, kad *SELECT* dalyje būtų pateikti identiški duomenys kaip treniravime.

Gauti rezultatai:

Row	predicted_d...	predict...	predicted_deposi...	job	marital	housing	contact	month	campaign_binary	pContact_combin...	poutcome	deposit
44	true	false	0.595766975282...	management	married	false	cellular	feb	0	0	unknown	true
		true	0.587368152137...									
		false	0.412631847862...									
45	true	true	0.587368152137...	management	married	false	cellular	feb	0	0	unknown	false
		false	0.412631847862...									
46	true	true	0.732416170484...	student	single	false	cellular	feb	1	0	unknown	true
		false	0.267583829515...									
47	true	true	0.649000233051...	admin.	single	false	cellular	feb	0	0	unknown	false
		false	0.35099766948...									
48	false	true	0.435642197719...	admin.	married	true	cellular	feb	1	1	failure	false
		false	0.564357802280...									
49	false	true	0.458398413910...	technician	married	true	cellular	feb	0	0	unknown	false
		false	0.541601586089...									
50	true	true	0.796258476699...	technician	divorced	false	telephone	jul	1	1	success	true

Pažvelgę į atsitiktinai pasirinktą rezultatų ištrauką, galime matyti, kaip veikia mūsų klasifikavimo modelis:

- predicted_deposit – tai modelio prognozė (ar klientas sutiks su indėliu);
- predicted_deposit_probs.label – tikėtina klasė, kuriai priskiriama didesnė tikimybė;
- predicted_deposit_probs.prob – modelio priskirta tikimybė, kad klientas sutiks su indėliu;
- deposit – tai tikroji reikšmė duomenyse, t. y. ar klientas iš tiesų pasirašė indėlio sutartį.

Pavyzdžiui, jei matome eilutę su:

- predicted_deposit: true,
- predicted_deposit_probs.prob: 0.67,
- deposit: false

tai reiškia, kad modelis su 67% tikimybe prognozavo, jog klientas susidomės pasiūlymu, tačiau realybėje jis to nepadarė – tai vadiname klaidingai teigiamu atveju (false positive).

Išvalgos

Nors modelio vertinimo metrika parodė, kad prognozės nėra idealios, atsitiktinai paimitas rezultatų intarpas leidžia daryti išvadą, jog modelis tikrai dažniau pataiko teisingai, nei klusta. Tai patvirtina ir faktas, kad daugelyje eilučių prognozė atitinka realybę.

Praktinė vertė

Toks modelis, nepaisant netobulumo, gali būti vertingas banko darbuotojams – jis padėtų prioritetizuoti klientus, kurie tikėtina priims pasiūlymą, taip sumažinant laiką, skiriamą mažai tikėtiniems atvejams. Tai padidina darbo efektyvumą ir sumažina išteklių švaistymą.

7. IŠVADOS

- Duomenų analizė atlikta su 11162 įrašais iš Kaggle. Naudota Google BigQuery platforma. Duomenys atsitiktinai padalyti į treniravimo (80%) ir testavimo (20%) rinkinius. Atliktos reikšmingos transformacijos: pašalinti, sujungti, transformuoti kintamieji – palikti svarbiausieji
- Sukurtas klasifikavimo modelis, prognozuojantis, ar banko klientas sutiks sudaryti terminuotą indėlį, remiantis telemarketingo duomenimis. Modelis padeda bankui taikliau nukreipti rinkodaros pastangas ir sumažinti išteklių švaistymą.
- Modelio (v10) rezultatai rodo pagerėjusį F1 rodiklį (0.6519) palyginus su pradiniu (v1 F1 – 0.6337) modeliu. Nors *precision* šiek tiek sumažėjo, bendras balansas tarp klaidingų teigiamų ir neigiamų prognozių pagerėjo. Modelis teisingai prognozuoja ~69% atvejų.
- Sezoniškumo analizė atskleidė, kad klientai palankiau reaguoja pavasarį, rudenį ir gruodį, o vasarą dažniau atsisako. Šios išvalgos gali padėti planuoti efektyvesnes skambučių kampanijas.
- **Modelis leidžia taupyti laiką banko darbuotojams, koncentruotis į tinkamus klientus, lengvai interpretuojamas ir gali būti taikomas realiame banko darbe.**
- Norint pagerinti modelį ateityje, galima naudoti duomenų balansavimą, išbandyti kitus algoritmus, mašininio mokymo, algoritmus.